Classification

Classification task

$\mathbb{X} = \mathbb{R}^d$ — пространство объектов

$$Y = \{-1, +1\}$$

$$X = \{(x_i, y_i)\}_{i=1}^{\ell}$$

Logistic regression

Линейная модель классификации определяется следующим образом:

$$a(x) = \text{sign}\left(\langle w, x\rangle + w_0\right) = \text{sign}\left(\sum_{j=1}^{d} w_j x_j + w_0\right),$$

$$a(x) = \text{sign}\langle w, x\rangle$$

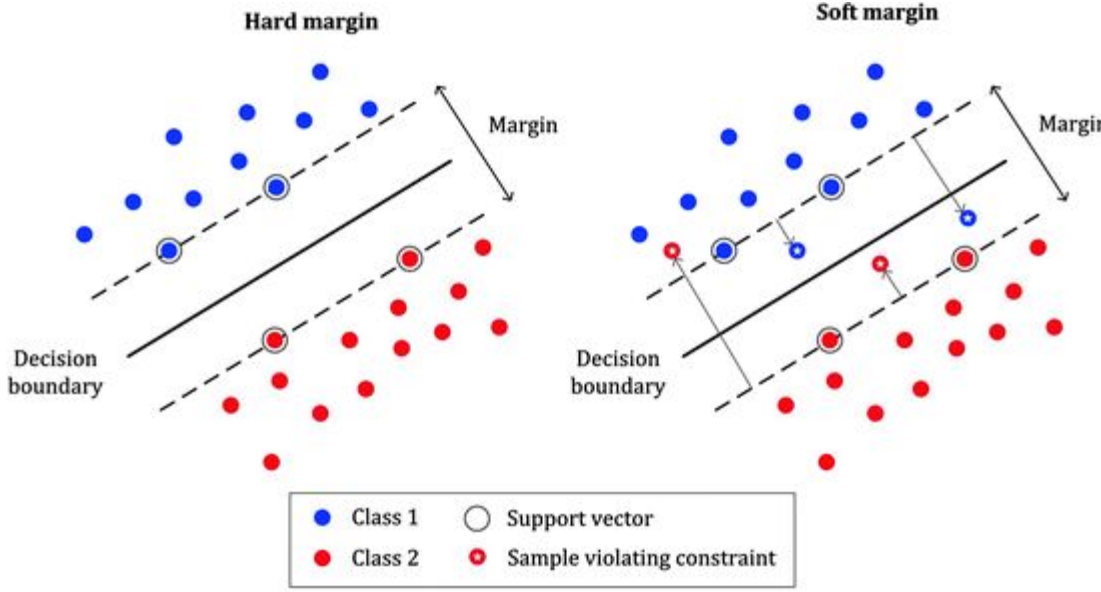
Accuracy

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) = y_i]$$

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) \neq y_i] = \frac{1}{\ell} \sum_{i=1}^{\ell} [\text{sign}\langle w, x_i \rangle \neq y_i] \to \min_w$$

Margin

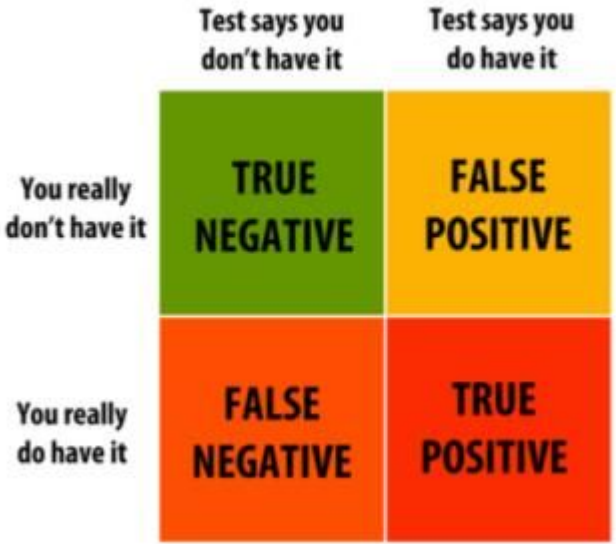
$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [\underbrace{y_i \langle w, x_i \rangle}_{M_i} < 0] \to \min_w$$



Quality metrics

$$\text{accuracy}(a, x) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) = y_i]$$

Quality metrics



$$\text{accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{FN} + \text{TN}}$$

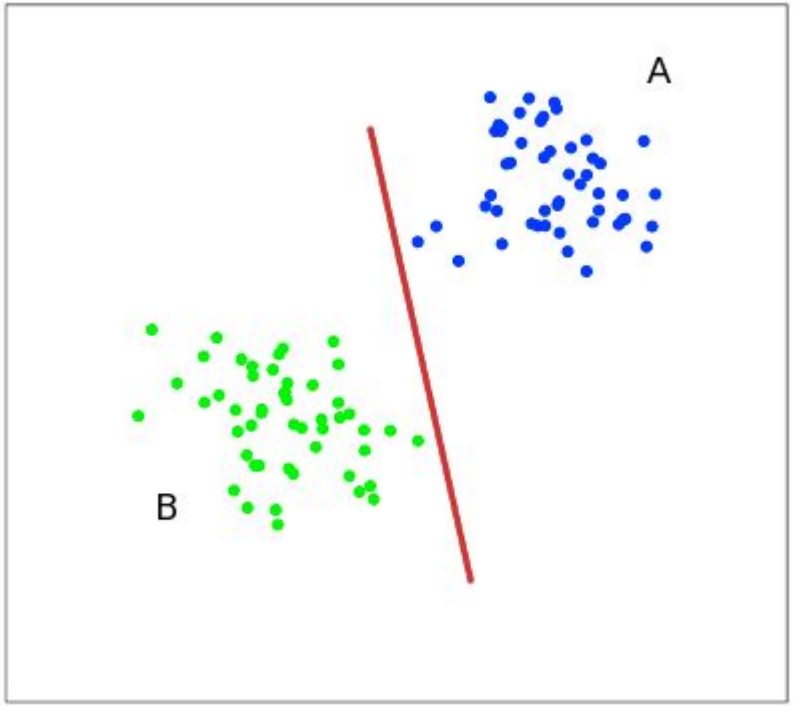
$$\text{precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

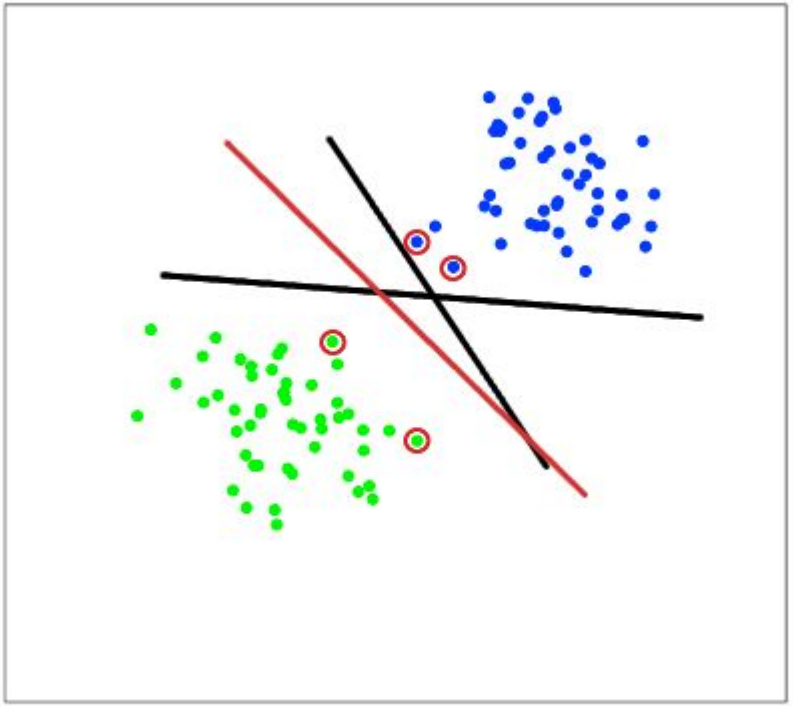
$$\text{recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}.$$

F

$$F = \frac{2 * \text{precision} * \text{recall}}{\text{precision} + \text{recall}}$$

SVM





Многоклассовая классификация

Как сделать из бинарной классификации многоклассовую?

Многоклассовая классификация

- One vs all
- All vs all
- Многоклассовые модели

$$\mathrm{SoftMax}(z_1, \ldots, z_K) = \left(\frac{\exp(z_1)}{\sum_{k=1}^{K} \exp(z_k)}, \ldots, \frac{\exp(z_K)}{\sum_{k=1}^{K} \exp(z_k)} \right)$$

Категориальные признаки - One Hot Encoding

One-hot
00000001
00000010
00000100
00001000
00010000
00100000
01000000
10000000

Счётчики

В общем случае - замена категориальной переменной на статистику по объектам этой категории (например средний таргет)

В случае бинарной классификации - категориальная переменная заменяется на процент объектов положительного класса данной категории